# Разрешение анафоры и кореферентности в текстах:

методы, метрики и ресурсы

Максим Ионов max.ionov@gmail.com

Goethe University Frankfurt / OТи $\Pi$ Л MГУ

Летняя школа АОТиАД, 27.07.2017

#### Outline

- 1 Понятия референции, кореферентности и анафоры
- Постановка задачи и методы решения
  - Разрешение (местоименной) анафоры
  - Разрешение кореферентности
- 3 Метрики и ресурсы
  - Оценка качества: анафора

Понятия референции, кореферентности и анафоры Постановка задачи и методы решения Метрики и ресурсы

#### Референция

- Не обязательно конкретные:
  - (1) I saw some people.

- Не обязательно конкретные:
  - (1) I saw some people.
- Не обязательно действительности:
  - (2) I saw a unicorn.

- Не обязательно конкретные:
  - (1) I saw some people.
- Не обязательно действительности:
  - (2) I saw a unicorn.
- Не обязательно объекты:
  - (3) The talk is about reference.

Референция — это способ указания на конкретные объекты действительности.

- Не обязательно конкретные:
  - (1) I saw some people.
- Не обязательно действительности:
  - (2) I saw a unicorn.
- Не обязательно объекты:
  - (3) The talk is about reference.

Референция — это способ указывать на сущности в дискурсе.

(4) I saw a unicorn in the forest. It was white. I hope I will see this animal again.

- (4) I saw a unicorn in the forest. It was white. I hope I will see this animal again.
- 3 сущности: I, unicorn, forest

- (4) I saw a unicorn in the forest. It was white. I hope I will see this animal again.
- 3 сущности: I, unicorn, forest
- a unicorn первое упоминание (discourse-new entity)

- (4) I saw a unicorn in the forest. It was white. I hope I will see this animal again.
- 3 сущности: *I, unicorn, forest*
- a unicorn первое упоминание (discourse-new entity)
- the forest указывает на конкретный лес

- (4) I saw a unicorn in the forest. It was white. I hope I will see this animal again.
- 3 сущности: I, unicorn, forest
- a unicorn первое упоминание (discourse-new entity)
- the forest указывает на конкретный лес
- unicorn it this animal указывает на одну и ту же сущность.

- (4) I saw a unicorn in the forest. It was white. I hope I will see this animal again.
- 3 сущности: I, unicorn, forest
- a unicorn первое упоминание (discourse-new entity)
- the forest указывает на конкретный лес
- unicorn it this animal указывает на одну и ту же сущность. Эти три именные группы кореферентны и образуют кореферентную цепочку (coreferential chain)

- (4) I saw a unicorn in the forest. It was white. I hope I will see this animal again.
- 3 сущности: I, unicorn, forest
- a unicorn первое упоминание (discourse-new entity)
- the forest указывает на конкретный лес
- unicorn it this animal указывает на одну и ту же сущность. Эти три именные группы кореферентны и образуют кореферентную цепочку (coreferential chain)
- местоимение, указывающее на другую именную группу случай анафоры

#### Используемые понятия

- Упоминание именная группа (с точки зрения дискурса)
- Референт сущность, к которой относятся некоторые ИГ
- Кореферентность (кореферентная связь) связь между двумя упоминаниями, которые относятся к одному и тому же элементу действительности

#### Используемые понятия

- Упоминание именная группа (с точки зрения дискурса)
- Референт сущность, к которой относятся некоторые ИГ
- Кореферентность (кореферентная связь) связь между двумя упоминаниями, которые относятся к одному и тому же элементу действительности
- Первое упоминание ИГ, вводящая новый элемент в дискурс
- Синглтон ИГ, не вступающая в кореферентную связь

#### Используемые понятия

- Упоминание именная группа (с точки зрения дискурса)
- Референт сущность, к которой относятся некоторые ИГ
- Кореферентность (кореферентная связь) связь между двумя упоминаниями, которые относятся к одному и тому же элементу действительности
- Первое упоминание ИГ, вводящая новый элемент в дискурс
- Синглтон ИГ, не вступающая в кореферентную связь
- Анафор местоимение, отсылающее к некоторой ИГ (второй элемент анафорической связи)
- Антецедент первый элемент анафорической связи, ИГ, к которой относится местоимение

• Философские аспекты

- Философские аспекты
- Синтаксическая анафора

- Философские аспекты
- Синтаксическая анафора
- Референциальный выбор

- Философские аспекты
- Синтаксическая анафора
- Референциальный выбор
- (Дискурсивная) анафора и разрешение кореферентности

- Философские аспекты
- Синтаксическая анафора
- Референциальный выбор
- (Дискурсивная) анафора и разрешение кореферентности сегодняшний доклад

- (5) a. Mary; saw herj.
  - b. \*Mary; saw her;.
  - c. \*Mary $_i$  saw herself $_j$ .
  - d. Mary; saw herself;.
  - e. \* Mary; saw Mary;

- (5) a. Mary; saw herj.
  - b. \*Mary; saw her;.
  - c.  $*Mary_i$  saw herself<sub>j</sub>.
  - d. Mary; saw herself;.
  - e. \* Mary; saw Mary;
- Эти ограничения касаются только анафоры

- (5) a. Mary; saw herj.
  - b. \*Mary; saw her;.
  - c.  $*Mary_i$  saw herself<sub>j</sub>.
  - d. Mary; saw herself;.
  - e. \* Mary; saw Mary;
- Эти ограничения касаются только анафоры
- Только внутри предложения

- (5) a. Mary; saw her;.
  - b. \*Mary; saw her;.
  - c.  $*Mary_i$  saw herself<sub>j</sub>.
  - d. Mary; saw herself;.
  - e. \* Mary; saw Mary;
- Эти ограничения касаются только анафоры
- Только внутри предложения
- ⇒ Не очень важно для обработки дискурса

- (5) a. Mary; saw her;.
  - b. \*Mary; saw her;.
  - c.  $*Mary_i$  saw herself<sub>j</sub>.
  - d. Mary; saw herself;.
  - e. \* Mary; saw Mary;
- Эти ограничения касаются только анафоры
- Только внутри предложения
- ⇒ Не очень важно для обработки дискурса (но чрезвычайно важно для теории языка)

В [Kibrik et al. 2010] (а также 2011 and 2013) представлена модель предсказания референциального выбора: выберет ли говорящий местоимение или полную ИГ в качестве упоминания. Некоторые важные признаки модели:

• Расстояние между анафором и антецедентом

- Расстояние между анафором и антецедентом
  - в предложениях
  - в абзацах
  - риторическое расстояние (в рамках теории риторических структур)

- Расстояние между анафором и антецедентом
  - в предложениях
  - в абзацах
  - риторическое расстояние (в рамках теории риторических структур)
- Протагонизм центральность референта в дискурсе

- Расстояние между анафором и антецедентом
  - в предложениях
  - в абзацах
  - риторическое расстояние (в рамках теории риторических структур)
- Протагонизм центральность референта в дискурсе
- Грамматические роли анафора и антецедента

## Разрешение анафоры и кореферентности

Задача NLP по автоматическому установлению анафорических и кореферентных связей

## Разрешение анафоры и кореферентности

Задача NLP по автоматическому установлению анафорических и кореферентных связей

 Важна для многих (почти всех) высокоуровневых задач NLP: извлечение фактов, машинный перевод, суммаризация, и т. д.

## Разрешение анафоры и кореферентности

Задача NLP по автоматическому установлению анафорических и кореферентных связей

- Важна для многих (почти всех) высокоуровневых задач NLP: извлечение фактов, машинный перевод, суммаризация, и т. д.
- Первые исследования появились на заре NLP

## Разрешение анафоры и кореферентности

Задача NLP по автоматическому установлению анафорических и кореферентных связей

- Важна для многих (почти всех) высокоуровневых задач NLP: извлечение фактов, машинный перевод, суммаризация, и т. д.
- Первые исследования появились на заре NLP
- Тем не менее, быстроразвивающаяся область, в особенности для low-resourced языков

## Разрешение анафоры и кореферентности

Задача NLP по автоматическому установлению анафорических и кореферентных связей

- Важна для многих (почти всех) высокоуровневых задач NLP: извлечение фактов, машинный перевод, суммаризация, и т. д.
- Первые исследования появились на заре NLP
- Тем не менее, быстроразвивающаяся область, в особенности для low-resourced языков
- (как обычно) Первые алгоритмы были основаны на правилах, сейчас большинство основано на машинном обучении

## Разрешение анафоры и кореферентности

Задача NLP по автоматическому установлению анафорических и кореферентных связей

- Важна для многих (почти всех) высокоуровневых задач NLP: извлечение фактов, машинный перевод, суммаризация, и т. д.
- Первые исследования появились на заре NLP
- Тем не менее, быстроразвивающаяся область, в особенности для low-resourced языков
- (как обычно) Первые алгоритмы были основаны на правилах, сейчас большинство основано на машинном обучении

Доклад посвящен именно этой задаче

- Анафора ← уровень текста, грамматики
- Кореферентность ← уровень дискурса

- Анафора ← уровень текста, грамматики
- Кореферентность ← уровень дискурса

С точки зрения NLP, задача разрешения анафоры — частный случай разрешения кореферентности.

- Анафора ← уровень текста, грамматики
- Кореферентность ← уровень дискурса

С точки зрения NLP, задача разрешения анафоры — частный случай разрешения кореферентности. (Poesio 2010):

Interpreting anaphoric expressions is one of the most fundamental aspects of language interpretation. The study of anaphora and anaphora resolution (also known in Computational Linguistics as coreference resolution) as brought about

Понятия референции, кореферентности и анафоры Постановка задачи и методы решения Метрики и ресурсы

## Разрешение анафоры как частный случай разрешения кореферентности

Понятия референции, кореферентности и анафоры Постановка задачи и методы решения Метрики и ресурсы

# Разрешение анафоры как частный случай разрешения кореферентности

#### Некоторые отличия:

• Методы оценки разрешения анафоры значительно проще

- Методы оценки разрешения анафоры значительно проще
- Анафору можно разрешать с меньшим количеством экстралингвистической информации

- Методы оценки разрешения анафоры значительно проще
- Анафору можно разрешать с меньшим количеством экстралингвистической информации
- Выделение всех упоминаний для разрешения анафоры тривиально

- Методы оценки разрешения анафоры значительно проще
- Анафору можно разрешать с меньшим количеством экстралингвистической информации
- Выделение всех упоминаний для разрешения анафоры тривиально (более или менее)

- Методы оценки разрешения анафоры значительно проще
- Анафору можно разрешать с меньшим количеством экстралингвистической информации
- Выделение всех упоминаний для разрешения анафоры тривиально (более или менее)
  - (6) It is raining.

### Задача

- з: Великолепная «Школа злословия» вернулась в эфир после летних каникул в новом формате.
- 4: В истории программы это уже не первый «ребрендинг».
- 5. Сейчас с трудом можно припомнить, что начиналась «Школа...» на канале «Культура» как стандартное ток-шоу, которое отличалось от других «кухонными» обсуждениями гостя, что называется «за глаза», и неожиданными персонами в качестве ведущих.
- Писательница Татьяна Толстая и сценаристка Дуня Смирнова вроде бы не вполне соответствовали принятым на российском телевидении стандартам телеведущих.
- 7. Впрочем, на канале «Культура» в роли телеведущих выступают и писатели, и композиторы, так что в этом ничего сверхъестественного не было, а идея кухонных обсуждений не слишком прижилась, и некоторые выпуски программы обходились практически без них.

практически без них.

### Задача

з. Великолепная «Школа злословия» вернулась в эфир после летних каникул в новом формате.

4. В истории программы это уже не первый «ребрендинг».

5. Сейчас с трудом можно припомнить, что начиналась «Школа...» на канале «Культура» как стандартное ток шоу, которое отличалось от других «кухонными» обсуждениями гостя, что называется − «за глаза», и неожиданными персонами в качестве ведущих.

6. Писательница Татьяна Толстая и сценаристка Дуня Смирнова вроде бы не вполне соответствовали принятым на российском телевидении стандартам телеведущих.

7. Впрочем, на канале «Культура» в роли телеведущих выступают и писатели, и композиторы, так что в этом ничего сверхъестественного не было, а идея кухонных

обсуждений не слишком прижилась, и некоторые выпуски программы обходились

### Outline

- Понятия референции, кореферентности и анафоры
- 2 Постановка задачи и методы решения
  - Разрешение (местоименной) анафоры
  - Разрешение кореферентности
- 3 Метрики и ресурсы
  - Оценка качества: анафора

#### Contents

- 1 Понятия референции, кореферентности и анафоры
- 2 Постановка задачи и методы решения
  - Разрешение (местоименной) анафоры
  - Разрешение кореферентности
- 3 Метрики и ресурсы
  - Оценка качества: анафора

• Формулировка задачи: для каждого (?) местоимения в тексте найти его антецедент.

- Формулировка задачи: для каждого (?) местоимения в тексте найти его антецедент.
- Правиловые подходы: модель generate-filter-rank:

- Формулировка задачи: для каждого (?) местоимения в тексте найти его антецедент.
- Правиловые подходы: модель generate-filter-rank:
  - Для каждого анафора выделение ИГ-кандидатов

- Формулировка задачи: для каждого (?) местоимения в тексте найти его антецедент.
- Правиловые подходы: модель generate-filter-rank:
  - Для каждого анафора выделение ИГ-кандидатов
  - Фильтрация кандидатов, нарушающих ограничения (например, согласование по роду и числу)

- Формулировка задачи: для каждого (?) местоимения в тексте найти его антецедент.
- Правиловые подходы: модель generate-filter-rank:
  - Для каждого анафора выделение ИГ-кандидатов
  - Фильтрация кандидатов, нарушающих ограничения (например, согласование по роду и числу)
  - Ранжирование оставшихся гипотез согласно предпочтениям (активированность референта, расстояние между анафором и антецедентом)

- Формулировка задачи: для каждого (?) местоимения в тексте найти его антецедент.
- Правиловые подходы: модель generate-filter-rank:
  - Для каждого анафора выделение ИГ-кандидатов
  - Фильтрация кандидатов, нарушающих ограничения (например, согласование по роду и числу)
  - Ранжирование оставшихся гипотез согласно предпочтениям (активированность референта, расстояние между анафором и антецедентом)
- Отбор кандидатов стоит ограничивать по расстоянию:
   > 90% антецедентов находятся в том же или предыдущем предложении, что и анафор (напр., [Hobbs 1978]).

Результаты для простых эвристик (на материале корпуса RuCor):

- Бейзлайн: выбор ближайшего ИГ
- Более сложный бейзлайн: выбор ближайшего совпадающего по роду и числу ИГ + простые эвристики для разных типов местоимений

Table 1: Качество разрешения анафоры при подходе, основанном на правилах

	P	R	$F_1$
Baseline	37.2%	35.7%	36.4%
Baseline + rules	56.5%	51.6%	53.9%

 Бинарная классификация для каждой гипотезы антецедент—анафор

- Бинарная классификация для каждой гипотезы антецедент—анафор
- Можно применять предварительную фильтрацию, используя строгие ограничения

- Бинарная классификация для каждой гипотезы антецедент—анафор
- Можно применять предварительную фильтрацию, используя строгие ограничения
- Проблема несбалансированного множества: отрицательных примеров значительно больше

Разрешение (местоименной) анафоры Разрешение кореферентности

## Разрешение анафоры: использование машинного обучения

- LenDist: признаки длины и расстояния.
  - Длина ИГ-кандидата в символах.
  - Длина кандидата в словах.
  - Расстояние между местоимением и ИГ в символах.
  - Расстояние между местоимением и ИГ в словах.
  - Расстояние между местоимением и ИГ в группах.

- AGR: признаки согласования между ИГ и местоимением.
  - Показатель числа ИГ-кандидата.
  - Показатель числа местоимения.
  - Совпадают ли показатели числа у кандидата и местоимения.

- SALIENCE: признаки, коррелирующие с салиентностью (активированностью).
  - Падеж ИГ.
  - Падеж местоимения.
  - Совпадают ли падежи у ИГ и местоимения.
  - Является ли кандидат именем собственным
  - Количество вхождений кандидата в тексте.
  - Тип местоимения.
  - Само местоимение.

#### Contents

- 1 Понятия референции, кореферентности и анафоры
- 2 Постановка задачи и методы решения
  - Разрешение (местоименной) анафоры
  - Разрешение кореферентности
- 3 Метрики и ресурсы
  - Оценка качества: анафора

• Формулировка задачи: разбить множество упоминаний на кореферентные цепочки.

- Формулировка задачи: разбить множество упоминаний на кореферентные цепочки.
- Получение множества упоминаний:

- Формулировка задачи: разбить множество упоминаний на кореферентные цепочки.
- Получение множества упоминаний:
  - Все ИГ: сильно зависит от морфологического анализа и более «нижних» уровней анализа

- Формулировка задачи: разбить множество упоминаний на кореферентные цепочки.
- Получение множества упоминаний:
  - Все ИГ: сильно зависит от морфологического анализа и более «нижних» уровней анализа
  - ИГ, данные извне: не подходит для практического применения, но позволяет тестировать непосредственно алгоритм разрешения кореферентности

- Формулировка задачи: разбить множество упоминаний на кореферентные цепочки.
- Получение множества упоминаний:
  - Все ИГ: сильно зависит от морфологического анализа и более «нижних» уровней анализа
  - ИГ, данные извне: не подходит для практического применения, но позволяет тестировать непосредственно алгоритм разрешения кореферентности
  - Предварительно отфильтрованные (кореферентные) ИГ: без синглтонов

# Разрешение кореферентности: различные модели

- MENTION-PAIR:
  - Генерируются пары-гипотезы
  - Для каждой пары решается, кореферентны ли ИГ
  - Кореферентные пары группируются в цепочки

# Разрешение кореферентности: различные модели

- MENTION-PAIR:
  - Генерируются пары-гипотезы
  - Для каждой пары решается, кореферентны ли ИГ
  - Кореферентные пары группируются в цепочки
- ENTITY-MENTION:
  - Генерируется список ИГ
  - Для каждой ИГ решается, к какой цепочке ее отнести (либо создать новую)

## Разрешение кореферентности: различные модели

- MENTION-PAIR:
  - Генерируются пары-гипотезы
  - Для каждой пары решается, кореферентны ли ИГ
  - Кореферентные пары группируются в цепочки
- ENTITY-MENTION:
  - Генерируется список ИГ
  - Для каждой ИГ решается, к какой цепочке ее отнести (либо создать новую)
- Есть и другие модели: глобальное обучение, турнирная модель, etc.

 Простейшая модель для разрешения кореферентности с использованием МІ

- Простейшая модель для разрешения кореферентности с использованием ML
- Генерация гипотез: для каждой пары анафор + антецедент из обучающей выборки:

- Простейшая модель для разрешения кореферентности с использованием ML
- Генерация гипотез: для каждой пары анафор + антецедент из обучающей выборки:
  - Положительный пример: сама пара
  - Отрицательные примеры: анафор + ИГ, расположенные между положительной парой

- Простейшая модель для разрешения кореферентности с использованием ML
- Генерация гипотез: для каждой пары анафор + антецедент из обучающей выборки:
  - Положительный пример: сама пара
  - Отрицательные примеры: анафор + ИГ, расположенные между положительной парой
- Объединение пар в цепочки:
  - CLOSE-FIRST: в цепочку объединяется анафор и ближайший возможный антецедент
  - ВЕST-FIRST: в цепочку объединяется пара с наибольшей вероятностью

- Простейшая модель для разрешения кореферентности с использованием ML
- Генерация гипотез: для каждой пары анафор + антецедент из обучающей выборки:
  - Положительный пример: сама пара
  - Отрицательные примеры: анафор + ИГ, расположенные между положительной парой
- Объединение пар в цепочки:
  - CLOSE-FIRST: в цепочку объединяется анафор и ближайший возможный антецедент
  - Best-first: в цепочку объединяется пара с наибольшей вероятностью
  - и многие другие стратегии

# Pазрешение кореферентности: MENTION-PAIR и ENTITY-MENTION

- Модель имеет серьезный недостаток: она не использует глобальную информацию, что приводит к «глупым» ошибкам: пары  $Hilary\ Clinton 
  ightarrow Clinton\ on \ Clinton 
  ightarrow he$  могут объединиться в одну цепочку
- Модель Entity-Mention является наиболее приближенной к когнитивным процессам

 Строковые: полное или частичное совпадение ИГ, совпадение вершин, альтернативное написание, расстояние между ИГ.

- Строковые: полное или частичное совпадение ИГ, совпадение вершин, альтернативное написание, расстояние между ИГ.
- Грамматические признаки ИГ-кандидата или анафора: является ли ИГ местоимением, определенность, наличие указательных местоимений.

- Строковые: полное или частичное совпадение ИГ, совпадение вершин, альтернативное написание, расстояние между ИГ.
- Грамматические признаки ИГ-кандидата или анафора: является ли ИГ местоимением, определенность, наличие указательных местоимений.
- Грамматические признаки сочетания ИГ-кандидата и анафора: согласование по лицу, числу, являются ли обе ИГ именами собственными, находится ли одна ИГ в аппозитивной или предикативной позиции относительно другой, синтаксические роли ИГ.

- Строковые: полное или частичное совпадение ИГ, совпадение вершин, альтернативное написание, расстояние между ИГ.
- Грамматические признаки ИГ-кандидата или анафора: является ли ИГ местоимением, определенность, наличие указательных местоимений.
- О Грамматические признаки сочетания ИГ-кандидата и анафора: согласование по лицу, числу, являются ли обе ИГ именами собственными, находится ли одна ИГ в аппозитивной или предикативной позиции относительно другой, синтаксические роли ИГ.
- Семантические свойства: семантические отношения двух ИГ (синонимия, гиперонимия), совпадают ли семантические классы двух ИГ.

- Строковые: полное или частичное совпадение ИГ, совпадение вершин, альтернативное написание, расстояние между ИГ.
- Грамматические признаки ИГ-кандидата или анафора: является ли ИГ местоимением, определенность, наличие указательных местоимений.
- Орамматические признаки сочетания ИГ-кандидата и анафора: согласование по лицу, числу, являются ли обе ИГ именами собственными, находится ли одна ИГ в аппозитивной или предикативной позиции относительно другой, синтаксические роли ИГ.
- Семантические свойства: семантические отношения двух ИГ (синонимия, гиперонимия), совпадают ли семантические классы двух ИГ.
- Типы упоминаний: является ли ИГ синглтоном, является

#### Outline

- Понятия референции, кореферентности и анафоры
- ② Постановка задачи и методы решения
  - Разрешение (местоименной) анафоры
  - Разрешение кореферентности
- 3 Метрики и ресурсы
  - Оценка качества: анафора

#### Contents

- Понятия референции, кореферентности и анафоры
- ② Постановка задачи и методы решения
  - Разрешение (местоименной) анафоры
  - Разрешение кореферентности
- Метрики и ресурсы
  - Оценка качества: анафора

 Anaphora resolution task is simple: for every pronoun restore its antecedent

- Anaphora resolution task is simple: for every pronoun restore its antecedent
- Classification task: classify all pronouns as a match for the antecedent

- Anaphora resolution task is simple: for every pronoun restore its antecedent
- Classification task: classify all pronouns as a match for the antecedent
- We can simply use the Accuracy metric (% of correctly resolved anaphoric links)...

- Anaphora resolution task is simple: for every pronoun restore its antecedent
- Classification task: classify all pronouns as a match for the antecedent
- We can simply use the Accuracy metric (% of correctly resolved anaphoric links)...
- But we want to know the recall as well

- Anaphora resolution task is simple: for every pronoun restore its antecedent
- Classification task: classify all pronouns as a match for the antecedent
- We can simply use the Accuracy metric (% of correctly resolved anaphoric links)...
- But we want to know the recall as well
- Some algorithms may resolve something for each pronoun

- Anaphora resolution task is simple: for every pronoun restore its antecedent
- Classification task: classify all pronouns as a match for the antecedent
- We can simply use the Accuracy metric (% of correctly resolved anaphoric links)...
- But we want to know the recall as well
- Some algorithms may resolve something for each pronoun
- Some may yield only precise results

- Anaphora resolution task is simple: for every pronoun restore its antecedent
- Classification task: classify all pronouns as a match for the antecedent
- We can simply use the Accuracy metric (% of correctly resolved anaphoric links)...
- But we want to know the recall as well
- Some algorithms may resolve something for each pronoun
- Some may yield only precise results
- ⇒ A combination of precision and recall gives more transparent results

# Evaluation metrics: anaphora

TP # of pairs correctly classified as true
 FP # of pairs incorrectly classified as true
 FN # of pairs incorrectly classified as false

# Evaluation metrics: anaphora

- TP # of pairs correctly classified as true
   FP # of pairs incorrectly classified as true
   FN # of pairs incorrectly classified as false
- From this we can get precision, recall and F-measures:

$$P = rac{N_{correct}}{N_{found}}$$
 $R = rac{N_{correct}}{N_{total}}$ 
 $F_1 = rac{2 \cdot P \cdot R}{P + R}$ 

Coreference resolution task can't be evaluated this way, since chains are sets:

Overlap

- Overlap
- Two chains in GS, one chain in test results

- Overlap
- Two chains in GS, one chain in test results
- One chain in GS, two chains in test results

- Overlap
- Two chains in GS, one chain in test results
- One chain in GS, two chains in test results
- . . .

There are various ways to evaluate this:

There are various ways to evaluate this:

Jaccard coefficient

There are various ways to evaluate this:

- Jaccard coefficient
- MUC-score

There are various ways to evaluate this:

- Jaccard coefficient
- MUC-score
- B<sup>3</sup>

$$Jac(C_1, C_2) = \frac{C_1 \cap C_2}{C_1 \cup C_2},$$

where  $C_1$  and  $C_2$  are chains represented by sets

• All mentions forms equivalency classes (EC)

- All mentions forms equivalency classes (EC)
- Each class represents one coreferential chain

- All mentions forms equivalency classes (EC)
- Each class represents one coreferential chain
- Metric value means the differences in the number of connections: the minimum number of links between mentions to be inserted or deleted when mapping a system response to a gold standard key set.

$$S$$
 — Set of EC in GS

$$R$$
 — Set of EC in test results

$$p(S)$$
 — partition of S relatively to the result

$$c(S) = (|S| - 1)$$
 — minimal number of links to get S

$$\mathit{m}(S) = (|\mathit{p}(S)| - 1)$$
 — number of missing links in R compared with GS

$$S$$
 — Set of EC in GS

$$R$$
 — Set of EC in test results

$$p(S)$$
 — partition of S relatively to the result

$$c(S) = (|S| - 1)$$
 — minimal number of links to get S

$$m(S) = (|p(S)| - 1)$$
 — number of missing links in R compared with GS

$$P = \frac{\sum_{i} (|R_{i}| - |p(R_{i})|)}{\sum_{i} (|R_{i}| - 1)}$$

$$R = \frac{\sum_{i} (|S_{i}| - |p(S_{i})|)}{\sum_{i} (|S_{i}| - 1)}$$

MUC-score is not perfect:

#### MUC-score is not perfect:

• Singletons (chains of length 1) are not accounted at all (there are no connections)

#### MUC-score is not perfect:

- Singletons (chains of length 1) are not accounted at all (there are no connections)
- All mistakes are equal: erroneous adding one element to a big chain is equal to merging two big chains

#### MUC-score is not perfect:

- Singletons (chains of length 1) are not accounted at all (there are no connections)
- All mistakes are equal: erroneous adding one element to a big chain is equal to merging two big chains

B<sup>3</sup> score was created to overcome this:

#### MUC-score is not perfect:

- Singletons (chains of length 1) are not accounted at all (there are no connections)
- All mistakes are equal: erroneous adding one element to a big chain is equal to merging two big chains

B<sup>3</sup> score was created to overcome this:

• Count precision and recall separately for every referent

#### MUC-score is not perfect:

- Singletons (chains of length 1) are not accounted at all (there are no connections)
- All mistakes are equal: erroneous adding one element to a big chain is equal to merging two big chains

B<sup>3</sup> score was created to overcome this:

- Count precision and recall separately for every referent
- Result is a weighted sums of those scores

$$P_i = \frac{N \text{ true elements in test results with a referent}_i}{N \text{ elements in a chain with referent}_i}$$

$$R_i = \frac{N \text{ true elements in test results with a referent}_i}{N \text{ elements in a GS chain with referent}_i}$$

$$P_i = \frac{N \text{ true elements in test results with a referent}_i}{N \text{ elements in a chain with referent}_i}$$

$$R_i = \frac{N \text{ true elements in test results with a referent}_i}{N \text{ elements in a GS chain with referent}_i}$$

Overall quality:

$$P = \sum_{i=1}^{N} w_i \cdot P_i$$

$$R = \sum_{i=1}^{N} w_i \cdot R_i$$

$$P_i = \frac{N \text{ true elements in test results with a referent}_i}{N \text{ elements in a chain with referent}_i}$$

$$R_i = \frac{N \text{ true elements in test results with a referent}_i}{N \text{ elements in a GS chain with referent}_i}$$

Overall quality:

$$P = \sum_{i=1}^{N} w_i \cdot P_i$$

$$R = \sum_{i=1}^{N} w_i \cdot R_i$$

Weights can be set depending on the task

• B<sup>3</sup> can count some chains more than once, and this makes the results less fair

- B<sup>3</sup> can count some chains more than once, and this makes the results less fair
- Constrained Entity-Alignment F-Measure (CEAF)

- B<sup>3</sup> can count some chains more than once, and this makes the results less fair
- Constrained Entity-Alignment F-Measure (CEAF)
- A lot of varieties: CEAF<sub>m</sub>, CEAF<sub>e</sub>, etc.

- B<sup>3</sup> can count some chains more than once, and this makes the results less fair
- Constrained Entity-Alignment F-Measure (CEAF)
- A lot of varieties: CEAF<sub>m</sub>, CEAF<sub>e</sub>, etc.
- Compares the sets of aligned coreference chains

MUC penalizes missing links:

• MUC penalizes missing links: A simple baseline, all mentions form one chain, gives us MUC  $F_1$ -score  $\approx 85\%$ 

- MUC penalizes missing links: A simple baseline, all mentions form one chain, gives us MUC  $F_1$ -score  $\approx 85\%$
- B<sup>3</sup> measures quality for an average chain

- MUC penalizes missing links: A simple baseline, all mentions form one chain, gives us MUC  $F_1$ -score  $\approx 85\%$
- B<sup>3</sup> measures quality for an average chain
- CEAF measures the *similarity* between two sets of chains

CoNIT reference scorer

- CoNLL reference scorer
- https:

//github.com/conll/reference-coreference-scorers

- CoNLL reference scorer
- https:

//github.com/conll/reference-coreference-scorers

• A reliable way to compute all the scores

• There are a lot of copora for a number of languages:

- There are a lot of copora for a number of languages:
  - English: MUC, ACE, ...

- There are a lot of copora for a number of languages:
  - English: MUC, ACE, ...
  - German: TüBa-D/Z, ...

- There are a lot of copora for a number of languages:
  - English: MUC, ACE, ...
  - German: TüBa-D/Z, ...
  - and many others
- The only available coreference corpus is RuCoref (Toldova et al. 2014)

- There are a lot of copora for a number of languages:
  - English: MUC, ACE, ...
  - German: TüBa-D/Z, ...
  - and many others
- The only available coreference corpus is RuCoref (Toldova et al. 2014)
- It has around 181 texts and 3 638 coreferential chains

### Смежные задачи

- Определение упоминаний (mention detection)
- Использование внешних знаний

# Спасибо! Вопросы?

```
Kopпyc RuCor: http://rucoref.maimbava.net
```

Репозиторий: https://github.com/max-ionov/rucoref

Тетрадки Jupyter:

https://github.com/max-ionov/rucoref/tree/master/notebooks